

Modelo Preditivo de Precificação de Veículos Usados: Um Estudo de Caso do Toyota Corolla Sedã em São Paulo com *Machine Learning*

Leandro Zerbinatti o¹

¹Faculdade de Computação e Informática (FCI)
Universidade Presbiteriana Mackenzie – São Paulo, SP – Brasil

²Curso de Sistemas de Informação – Faculdade de Computação e Informática (FCI) –
Universidade Presbiteriana Mackenzie – São Paulo, SP – Brasil

{10418047,10403348,10417221,10419046}@mackenzista.com.br

Resumo. Este artigo apresenta o desenvolvimento de um modelo preditivo baseado em *Machine Learning* para precificação de veículos usados, com foco no Toyota Corolla Sedã no estado de São Paulo. O mercado de seminovos sofre de forte assimetria de informação, e métricas estáticas como a Tabela FIPE falham em incorporar variáveis dinâmicas como quilometragem e estado de conservação (VARIAN, 2019). Para mitigar essa limitação, foi construído um pipeline de extração via consumo direto de API REST, resultando em 3.470 anúncios brutos. Após processamento ETL com remoção de outliers via IQR e filtro de sanidade FIPE, o dataset final consolidou 3.311 anúncios válidos. Sobre essa base, foi treinado um modelo *RandomForestRegressor* que alcançou R^2 de 93,96% e MAE de R\$ 5.619,09 sobre o conjunto de teste, correspondendo a aproximadamente 4,8% do preço médio. O artefato foi encapsulado em uma interface interativa de previsão. O projeto documenta as implicações éticas e legais envolvidas, alinhando-se à Lei Geral de Proteção de Dados (LGPD) e adotando práticas de governança algorítmica para mitigar vieses.

Palavras-chave: *Machine Learning*; *Random Forest*; precificação preditiva; web scraping; API REST.

Abstract. This article presents the development of a *Machine Learning*-based predictive model for used vehicle pricing, focused on the Toyota Corolla Sedan in the State of São Paulo. The used car market suffers from strong information asymmetry, and static metrics such as the FIPE Table fail to incorporate dynamic variables such as mileage and conservation status (VARIAN, 2019). To mitigate this limitation, a data extraction pipeline was built via direct consumption of a REST API, resulting in 3,470 raw advertisements. After ETL processing with outlier removal via IQR and FIPE sanity filtering, the final dataset consolidated 3,311 valid advertisements. A *RandomForestRegressor* model was trained on this base, achieving an R^2 of 93.96% and MAE of R\$ 5,619.09 on the test set, corresponding to approximately 4.8% of the dataset's mean price. The artifact was encapsulated in an interactive prediction interface. The project documents the ethical and legal implications involved, aligning with the Brazilian General Data Protection Law (LGPD) and adopting algorithmic governance practices to mitigate biases.

Keywords: *Machine learning*; *Web scraping*; *Vehicle pricing*; *Statistical regression*; *Data analysis*.

1. Introdução

O mercado de veículos seminovos e usados no Brasil sofre de uma forte assimetria de informação. Conforme descrito por Varian (2019), a assimetria de informação ocorre quando uma das partes em uma transação comercial detém informações relevantes que a outra não possui, gerando ineficiências alocativas e distorções de preço. Compradores e vendedores utilizam frequentemente métricas generalistas e padronizadas para definir o valor dos automóveis; contudo, estas tabelas estáticas não capturam a realidade dinâmica do mercado, ignorando fatores cruciais de depreciação, como a quilometragem exata, a procura regional e o desgaste específico das diferentes versões e motorizações de um mesmo modelo.

1.1 Justificativa

Neste contexto, o Toyota Corolla Sedã foi escolhido para este estudo por ser um dos veículos de maior liquidez e retenção de valor no mercado sul-americano. Criar um modelo de precificação inteligente para este nicho específico permite identificar anomalias de mercado (carros subvalorizados ou sobrevalorizados) com alta precisão matemática, gerando uma vantagem analítica real para negociações e gestão de frotas.

1.2 Objetivo

O objetivo central deste trabalho é desenvolver um modelo preditivo baseado em algoritmos de *Machine Learning* capaz de estimar o preço justo de mercado de veículos do modelo Toyota Corolla Sedã no estado de São Paulo. O modelo utiliza dados reais e atualizados de anúncios para aprender os padrões de depreciação com base no ano de fabricação, versão e quilometragem rodada, superando as limitações das avaliações estáticas atualmente disponíveis ao mercado. Como objetivos específicos, o projeto busca: (i) coletar um dataset representativo e atualizado via consumo de *API REST*; (ii) realizar a limpeza e análise exploratória dos dados; (iii) treinar e validar um modelo de regressão; e (iv) entregar uma interface funcional de consulta ao modelo treinado.

1.4 Opção do projeto

Foi adotada a Opção *Framework*, empregando a biblioteca *Scikit-Learn* (PEDREGOSA et al., 2011) para implementação de um modelo de regressão supervisionada. A escolha se justifica pela natureza numérica contínua da variável-alvo (preço em reais) e pela disponibilidade consolidada de algoritmos de ensemble (*Random Forest*, *Gradient Boosting*) na biblioteca, que permitem capturar relações não lineares entre as features categóricas (versão, câmbio) e numéricas (ano, quilometragem) sem necessidade de engenharia manual de interações.

2. Descrição do problema

O problema central abordado por este projeto é a estimativa do preço justo de revenda de veículos usados em um mercado caracterizado por forte heterogeneidade de

oferta e assimetria de informação entre as partes da transação. No segmento de seminovos, dois veículos do mesmo modelo e ano podem apresentar diferenças de preço superiores a 50% em função de variáveis dinâmicas como quilometragem rodada, versão específica (motorização, pacote de opcionais), histórico de manutenção e estado de conservação, que não são capturadas por tabelas de referência estáticas como a Tabela FIPE.

A FIPE, principal referência adotada pelo mercado brasileiro, opera publicando preços médios mensais por modelo/ano, sem incorporar variáveis individuais do veículo. Essa limitação produz três efeitos práticos: (i) compradores tendem a sobre pagar por veículos cuja desvalorização real (por uso intensivo ou versão de menor liquidez) já é superior ao valor tabelado; (ii) vendedores tendem a subvalorizar veículos em condições privilegiadas (baixa quilometragem, versão premium em alta), perdendo margem de negociação; e (iii) revendedores e plataformas de seguro carecem de ferramenta objetiva para precificar individualmente cada ativo de seu inventário.

Formalmente, o problema configura-se como regressão supervisionada: dado um conjunto X de features observáveis (ano de fabricação, ano de modelo, versão, câmbio, quilometragem), o objetivo é aprender uma função $f(X) \rightarrow y$ que mapeie essas características ao valor monetário y praticado no mercado, minimizando uma métrica de erro como o MAE (*Mean Absolute Error*). A função f deve generalizar a partir de exemplos históricos observados em anúncios reais, capturando padrões não lineares de depreciação que escapam a fórmulas analíticas simples.

O escopo do projeto foi deliberadamente restrito a um único modelo (Toyota Corolla Sedã) em uma única região (estado de São Paulo) por três razões metodológicas: (a) o Corolla é um dos veículos de maior liquidez e retenção de valor no mercado brasileiro, garantindo volume amostral significativo; (b) a restrição geográfica controla a variância introduzida por diferenças regionais de mercado; e (c) o isolamento da carroceria Sedã elimina a contaminação por curvas de depreciação distintas (hatch, SUV) de modelos correlatos. Esse escopo focado permite ao modelo aprender com profundidade os padrões específicos do nicho, em vez de produzir aproximações genéricas vulneráveis a vieses de mistura.

3. Referencial Teórico

O conceito de assimetria de informação em mercados de bens usados foi amplamente estudado pela teoria econômica. Varian (2019) descreve como mercados com informação imperfeita produzem seleção adversa, onde o preço de equilíbrio tende a refletir a média do mercado em vez do valor real de cada ativo individual. No contexto automobilístico brasileiro, a Tabela FIPE opera precisamente nesta lógica: oferece um valor médio para determinado modelo/ano, ignorando o estado de conservação real do veículo.

O aprendizado de máquina supervisionado, especificamente para tarefas de regressão, permite que um algoritmo aprenda padrões a partir de dados históricos para realizar previsões numéricas contínuas. Segundo James et al. (2021), modelos de regressão estimam a função que relaciona variáveis independentes (*features*) a uma variável dependente (*target*), minimizando o erro de predição sobre o conjunto de treinamento. Para este projeto, as *features* são o Ano do Modelo, a Quilometragem e a Versão do veículo; a variável alvo é o preço de mercado. Géron (2019) detalha que algoritmos como a Regressão Linear Múltipla fornecem uma base interpretável, enquanto métodos de *ensemble* como *Random Forest* e *Gradient Boosting* geralmente oferecem maior capacidade preditiva ao capturar relações não lineares entre variáveis. Neste projeto, o algoritmo *Random Forest* foi selecionado como abordagem principal por seu desempenho documentado em problemas de regressão sobre *datasets* tabulares heterogêneos, com a métrica MAE (*Mean Absolute Error*) e o coeficiente R^2 adotados para avaliação do desempenho preditivo sobre o conjunto de teste.

A extração automatizada de dados de páginas *web*, conhecida como *web scraping*, consiste em recuperar e estruturar informações publicamente disponíveis. McKinney (2017) ressalta que a qualidade e a representatividade do dataset são determinantes para o desempenho de qualquer modelo analítico, justificando o investimento técnico na coleta de dados originais em detrimento de *datasets* genéricos. Para a extração propriamente dita, duas abordagens são tradicionalmente empregadas: o parsing direto de páginas HTML, suportado por bibliotecas como *Beautiful Soup* (RICHARDSON, 2023) e frameworks de automação de navegador como Selenium para páginas de renderização dinâmica; e o consumo direto das *APIs REST* internas das plataformas, quando estas estão acessíveis, oferecendo dados já estruturados em formato JSON e dispensando o parsing de HTML.

O *Scikit-Learn* é a biblioteca de *Machine Learning* mais amplamente adotada no ecossistema *Python* para fins científicos e de produção. Pedregosa et al. (2011) descrevem sua arquitetura baseada em uma API consistente (*fit/predict/transform*), que permite a implementação, validação cruzada e comparação de diferentes algoritmos com mínima refatoração de código, tornando-o ideal para projetos acadêmicos que demandam experimentação comparativa de modelos.

4. Aspectos Éticos e de Responsabilidade

No desenvolvimento desta solução analítica, o grupo observou rigorosamente os seguintes princípios éticos e de responsabilidade tecnológica:

Privacidade e Coleta de Dados: A extração de dados foi conduzida via consumo da API pública interna da plataforma, incidindo exclusivamente em informações comerciais de livre acesso (anúncios visíveis a qualquer visitante do site, sem necessidade de autenticação ou contornos de *paywalls*). Nenhum dado pessoal sensível de usuários ou vendedores (como nomes, contatos telefônicos, endereços ou documentos de identificação) foi extraído ou armazenado, garantindo o cumprimento integral da Lei Geral de Proteção de Dados (LGPD) vigente no Brasil. Adicionalmente, foram

aplicadas pausas aleatórias entre requisições para evitar sobrecarga ao servidor da plataforma, em respeito ao princípio de uso responsável de recursos computacionais de terceiros.

Transparência e Uso do Modelo: O algoritmo preditivo tem como propósito atuar como uma ferramenta de suporte à decisão matemática, e não como um instrumento absoluto de fixação de preços de mercado. A documentação do projeto garante a transparência de que o modelo opera com uma margem de erro estatística inerente, e os resultados devem ser interpretados como estimativas probabilísticas, não como valores determinísticos.

Prevenção de Vieses Algorítmicos: A equipe restringiu o escopo da coleta a uma região geográfica controlada e isolou o formato de carroceria (Sedã) para evitar que o modelo crie discriminações de preços baseadas na saturação de anúncios de diferentes regiões ou misture veículos de categorias com curvas de depreciação distintas. O modelo final foi testado para garantir que avalia os veículos puramente por seus atributos objetivos de conservação.

5. Metodologia

O desafio técnico consiste em prever o valor financeiro de um veículo usado considerando suas características únicas, mitigando a dependência de avaliações baseadas puramente em intuição humana ou em médias defasadas. Trata-se de um problema de regressão supervisionada, onde o modelo deve aprender, a partir de um conjunto de anúncios reais, a função de depreciação que mapeia as características observáveis de um veículo ao seu preço de mercado.

5.1 Evolução metodológica da coleta de dados

A abordagem inicial de coleta, descrita na primeira fase deste projeto (N1), utilizou a biblioteca *Selenium* em conjunto com *undetected_chromedriver* para automação do navegador, e *BeautifulSoup* (RICHARDSON, 2023) para o *parsing* do HTML renderizado. Contudo, ao longo da execução, essa estratégia revelou três limitações críticas: (i) instabilidade frente aos mecanismos *anti-bot* da plataforma, com taxa crescente de bloqueios e *CAPTCHAs*; (ii) custo computacional elevado pela necessidade de renderizar a página inteira para cada requisição; e (iii) fragilidade estrutural, dado que pequenas alterações no HTML da plataforma quebravam os seletores e exigiam manutenção recorrente.

Diante dessas limitações, na fase N2 a metodologia de extração foi reformulada para o consumo direto da API REST interna da plataforma (*endpoint /api/search/car*), via biblioteca *requests* e *parsing* nativo de JSON. A nova abordagem trouxe três ganhos significativos: (i) imunidade a alterações cosméticas no HTML; (ii) velocidade superior por dispensar a renderização do navegador; e (iii) resiliência reforçada pela ausência de elementos visuais a serem interpretados. Para contornar a autenticação implícita do *endpoint*, são injetados nos cabeçalhos da requisição os *cookies* de sessão e *headers* de

identificação (*User-Agent*, *sec-ch-ua*) extraídos previamente de uma sessão de navegação legítima e técnica equivalente à reprodução de uma chamada já autenticada pelo navegador do usuário.

5.2 Pipeline de coleta

O *script* desenvolvido executa paginação dinâmica até o esgotamento do estoque, com pausas aleatórias entre 2,5 e 5,5 segundos por requisição (e pausas estendidas de 20 segundos a cada 15 páginas) para emular comportamento humano e respeitar a carga do servidor. Um filtro determinístico aplicado em tempo de coleta descarta anúncios patrocinados oriundos de outros estados ou de outras carrocerias que a API eventualmente injeta nos resultados, garantindo a homogeneidade do escopo (Sedã, estado de SP). O processo resultou em 3.470 anúncios brutos, posteriormente duplicados pelo identificador único ID_Anuncio.

5.3 Pipeline de processamento (ETL)

Os dados brutos passam por um pipeline unificado de limpeza implementado em Pandas (MCKINNEY, 2017), composto por quatro etapas: (i) Limpeza estrutural, remoção de cabeçalhos eventualmente concatenados pelo modo *append* da coleta, normalização de espaços em branco e conversão de strings vazias para NaN; (ii) Tipagem rigorosa, conversão das colunas numéricas (preço, quilometragem, ano, percentual FIPE) para *int* ou *float* com descarte de registros não convertíveis; (iii) Tratamento estatístico de outliers, aplicação do método Intervalo Interquartil (IQR) sobre as colunas *Preco_Real* e *Quilometragem*, removendo registros fora do intervalo $[Q1 - 1,5 \cdot IQR, Q3 + 1,5 \cdot IQR]$, técnica clássica e não-paramétrica conforme James et al. (2021); (iv) Filtro de sanidade mercadológica, restrição dos anúncios à faixa de 50% a 150% da Tabela FIPE, sob a premissa de que valores fora desse intervalo geralmente indicam fraude, sinistro, blindagem ou erro de cadastro. Por fim, são descartadas colunas constantes no escopo filtrado (Marca, Modelo, Carroceria, Estado), por não agregarem variância informativa ao modelo. O dataset final consolidou 3.311 anúncios válidos (4,6% removidos em relação ao bruto).

5.4 Treinamento do modelo preditivo

Para a etapa preditiva, foi adotado o algoritmo *Random Forest Regressor* (*Scikit-Learn*), uma técnica de ensemble baseada em *bagging* de árvores de decisão. A escolha se baseia em três fatores: (i) capacidade nativa de capturar relações não lineares entre *features* sem necessidade de *feature engineering* manual; (ii) robustez a *outliers* residuais não removidos pelo IQR; e (iii) interpretabilidade preservada via importância de *features* (GÉRON, 2019).

As variáveis categóricas *Versao* (26 categorias únicas) e *Cambio* (2 categorias) foram codificadas via *one-hot encoding* com *drop_first=True* para evitar multicolinearidade. A ordem das colunas resultantes foi persistida em artefato separado (*colunas_treinamento.pkl*), garantindo consistência entre treinamento e inferência. A variável *Percentual_FIPE* foi deliberadamente removida do conjunto de *features* para evitar data leakage, dado que esta é matematicamente derivada da variável-alvo

Preco_Real, sua inclusão produziria métricas artificialmente otimistas sem capacidade real de generalização.

Os hiperparâmetros foram calibrados empiricamente: $n_estimators=150$ (quantidade de árvores no *ensemble*), $min_samples_leaf=5$ (mínimo de amostras por folha, restrição que força generalização e protege contra *overfitting*), $random_state=42$ (reprodutibilidade) e $n_jobs=-1$ (paralelização). O *dataset* foi particionado em 80% para treino (2.648 anúncios) e 20% para teste (663 anúncios) via `train_test_split` com seed fixa.

6. Resultados

Após o *pipeline* de processamento, o dataset final consolidou 3.311 anúncios válidos, dos 3.470 originalmente coletados (taxa de aproveitamento de 95,4%). A Tabela 1 apresenta as estatísticas descritivas das três variáveis numéricas principais.

Tabela 1 — Estatísticas Descritivas do Dataset Limpo (n = 3.311)

Variável	Mínimo	Mediana	Média	Máximo	Desvio
Preço (R\$)	18.900	121.900	117.916	221.607	37.655
Quilometragem (km)	0	78.658	83.076	230.000	51.641
Ano do Modelo	1998	2021	2020	2026	5

A amplitude de preços observada (de R\$ 18.900 para modelos finais dos anos 1990 com alta quilometragem de até R\$ 221.607 de modelos 2026 híbridos zero km) evidencia a forte heterogeneidade do mercado de Corolla em SP e a insuficiência de um único valor médio para representá-lo. O desvio padrão de R\$ 37.655 (aproximadamente 32% da média) confirma que a variância de preço é matematicamente significativa e dependente de características individuais do veículo, validando a escolha de uma abordagem preditiva baseada em features. O *dataset* contempla 26 versões únicas distintas do Corolla Sedã e dois tipos de câmbio (Automático e Manual).

A análise de correlação de *Pearson* aplicada sobre o *dataset* final confirma quantitativamente as hipóteses do projeto: $r = -0,808$ entre Quilometragem e Preço (correlação negativa forte) e $r = +0,907$ entre Ano do Modelo e Preço (correlação positiva muito forte). Esses coeficientes superam o limiar de $|r| > 0,7$ considerado por James et al. (2021) como indicativo de relação linear robusta, validando empiricamente a aplicabilidade de algoritmos de regressão sobre estas features.




Figura 1 — Dispersão e Distribuição de Preços do Dataset Limpo

A Figura 1 apresenta os dois gráficos produzidos durante a EDA: um *scatter plot* (dispersão) que evidencia a curva de depreciação em função do desgaste do veículo, e um *boxplot* que demonstra a distribuição de preços segmentada por ano de fabricação. O gráfico de dispersão (esquerda) confirma de forma visual e inequívoca a correlação negativa entre quilometragem rodada e preço de anúncio. Veículos com 0 km apresentam preços concentrados entre R\$ 150.000 e R\$ 220.000, enquanto veículos com 200.000 km ou mais raramente ultrapassam R\$ 80.000. Esta relação é consistente com os fundamentos econômicos de depreciação por uso. O *boxplot* por ano de modelo (direita) revela uma curva de valorização temporal clara: modelos do início dos anos 2000 concentram-se na faixa de R\$ 20.000–R\$ 40.000, enquanto os modelos de 2025–2026 atingem medianas superiores a R\$ 180.000. A presença de outliers em anos recentes indica anúncios de versões híbridas e de alto desempenho, que se distanciam do padrão de depreciação convencional da linha XEi/GLi, sugerindo que a variável "Versão" deveria exercer peso considerável no modelo preditivo final com a hipótese posteriormente confirmada.

6.2 Desempenho do Modelo Preditivo

O modelo *Random Forest Regressor* foi treinado sobre 2.648 anúncios (80%) e avaliado sobre 663 anúncios (20%) reservados para teste. As métricas de desempenho obtidas sobre o conjunto de teste foram:

- Coeficiente de Determinação (R^2): 93,96% — o modelo explica aproximadamente 94% da variância do preço de mercado a partir das features fornecidas (ano de fabricação, ano do modelo, versão, câmbio e quilometragem).
- Erro Médio Absoluto (MAE): R\$ 5.619,09 — em média, o preço previsto pelo modelo desvia em aproximadamente R\$ 5,6 mil do preço real anunciado.

Para contextualizar a magnitude do erro, o MAE obtido corresponde a apenas 4,76% do preço médio do dataset (R\$ 117.916) e a 2,77% da amplitude total de preços observada (R\$ 202.707, entre R\$ 18.900 e R\$ 221.607). Esses valores demonstram que o modelo captura adequadamente a função de depreciação do mercado de Corolla Sedã em SP, com generalização consistente sobre dados nunca vistos durante o treinamento e

ampla margem de superioridade sobre métricas estáticas como a Tabela FIPE, cujo desvio entre o valor tabelado e o preço real praticado costuma ser substancialmente maior em ativos com características dinâmicas (quilometragem, versão específica, ano de modelo).

6.3 Artefato Entregue

Os dois objetos resultantes do treinamento sendo o modelo serializado (modelo_corolla.pkl) e a ordem das colunas após *one-hot encoding* (colunas_treinamento.pkl), foram encapsulados em uma interface interativa (prever_interativo.py) que permite ao usuário final simular o preço justo de qualquer combinação de ano de fabricação, ano de modelo, versão, câmbio e quilometragem. A interface aplica filtros dinâmicos sobre o histórico do dataset para apresentar apenas combinações de versão/câmbio que efetivamente existiram nos anos selecionados, evitando consultas com semântica inválida.

7. Conclusão

O projeto concluiu com sucesso o ciclo completo proposto: da coleta de dados originais à entrega de um modelo preditivo funcional. A reformulação metodológica da etapa de coleta (de *Selenium* para consumo direto da API REST) trouxe robustez e escalabilidade ao *pipeline*, permitindo a expansão do *dataset* de 991 anúncios na N1 para 3.470 brutos / 3.311 finais na N2 — crescimento de aproximadamente 3,3 vezes que conferiu maior representatividade estatística ao modelo.

O modelo *Random Forest Regressor* implementado alcançou R^2 de 93,96% e MAE de R\$ 5.619,09 sobre o conjunto de teste, o erro que representa aproximadamente 4,76% do preço médio do *dataset*. Esses resultados demonstram capacidade preditiva consistente com os fundamentos econômicos de depreciação automotiva e validam empiricamente a hipótese inicial de que features dinâmicas (quilometragem, versão, ano) carregam poder explicativo significativo sobre o preço de mercado, superando as limitações de métricas estáticas como a Tabela FIPE, que opera com médias agregadas por modelo/ano.

Os objetivos específicos definidos na fase N1 foram integralmente atingidos: (i) coletado dataset original e atualizado; (ii) realizada limpeza e análise exploratória; (iii) treinado e validado o modelo de regressão; e (iv) entregue artefato funcional consumível via interface interativa. Como evolução natural do trabalho, propõem-se as seguintes direções futuras: (a) *benchmark* comparativo entre Random Forest, XGBoost e Gradient Boosting; (b) inclusão da Tabela FIPE como baseline numérica explícita para quantificar o ganho preditivo da abordagem de ML; (c) expansão para outros modelos e marcas com *pipeline* parametrizado; e (d) disponibilização do modelo como serviço REST (FastAPI) para integração com sistemas externos.

8. Endereço do Repositório e Vídeo de Apresentação

Repositório GitHub do projeto:

https://github.com/NicolasKEYT/preditor_de_preco_justo

Vídeo de apresentação no YouTube: <https://youtu.be/L0-sKSWZ5mA>

9. Referências

GÉRON, Aurélien. *Hands-on machine learning with Scikit-Learn, Keras, and TensorFlow: concepts, tools, and techniques to build intelligent systems*. 2. ed. Sebastopol: O'Reilly Media, 2019.

JAMES, G.; WITTEN, D.; HASTIE, T.; TIBSHIRANI, R. *An introduction to statistical learning: with applications in R*. 2. ed. New York: Springer, 2021.

MCKINNEY, Wes. *Python for data analysis: data wrangling with Pandas, NumPy, and IPython*. 2. ed. Sebastopol: O'Reilly Media, 2017.

PEDREGOSA, Fabian et al. Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, v. 12, p. 2825-2830, 2011.

RICHARDSON, Leonard. *Beautiful Soup Documentation*. 2023. Disponível em: <https://www.crummy.com/software/BeautifulSoup/bs4/doc/>. Acesso em: 24 mar. 2026.

VARIAN, Hal R. *Intermediate Microeconomics: A Modern Approach*. 9. ed. New York: W. W. Norton & Company, 2019.