

Modelo Preditivo de Precificação de Veículos Usados: Um Estudo de Caso do Toyota Corolla Sedã em São Paulo com *Machine Learning*

Leandro Zerbinatti o¹

¹Faculdade de Computação e Informática (FCI)
Universidade Presbiteriana Mackenzie – São Paulo, SP – Brasil

²Curso de Sistemas de Informação – Faculdade de Computação e Informática (FCI) –
Universidade Presbiteriana Mackenzie – São Paulo, SP – Brasil

{10418047,10403348,10417221,10419046}@mackenzista.com.br

Resumo. *Este artigo apresenta a proposta e a estruturação de dados para a criação de um modelo preditivo baseado em Machine Learning para a precificação de veículos usados, com foco no modelo Toyota Corolla Sedã na região da Grande São Paulo. O mercado automobilístico de seminovos apresenta forte assimetria de informação, dificultando a determinação de um preço justo, especialmente quando se utilizam métricas estáticas como a Tabela FIPE, que não incorporam variáveis dinâmicas cruciais, como quilometragem e estado real de conservação (Varian, 2019). Para mitigar esse problema, foi realizada a extração de 991 anúncios reais em plataformas online por meio de técnicas de web scraping. A etapa inicial aqui descrita compreende a higienização da base e a Análise Exploratória de Dados (EDA), que comprovou estatisticamente a correlação negativa entre o desgaste e o preço de mercado. Em etapas futuras, algoritmos de regressão serão aplicados utilizando o framework Scikit-Learn para estimar o valor justo do ativo. O projeto também documenta as implicações éticas e de responsabilidade legal (LGPD) na coleta e uso desses dados públicos.*

Palavras-chave: artigo científico; norma ABNT; trabalho de conclusão de curso.

Abstract. *This article presents the proposal and data structuring for the creation of a predictive model based on Machine Learning for the pricing of used vehicles, focusing on the Toyota Corolla Sedan in the Greater São Paulo region. The used car market presents strong information asymmetry, making it difficult to determine a fair price, especially when using static metrics such as the FIPE Table, which do not incorporate crucial dynamic variables such as mileage and real conservation status (Varian, 2019). To mitigate this problem, 991 real advertisements were extracted from online platforms using web scraping techniques. The initial stage described here comprises data cleaning and Exploratory Data Analysis (EDA), which statistically proved the negative correlation between wear and market price. In future stages, regression algorithms will be applied using the Scikit-Learn framework to estimate the fair value of the asset. The project also documents the ethical and legal responsibility implications (LGPD) in the collection and use of this public data.*

Keywords: Machine learning; Web scraping; Vehicle pricing; Statistical regression; Data analysis.

1. Introdução

O mercado de veículos seminovos e usados no Brasil sofre de uma forte assimetria de informação. Conforme descrito por Varian (2019), a assimetria de informação ocorre quando uma das partes em uma transação comercial detém informações relevantes que a outra não possui, gerando ineficiências alocativas e distorções de preço. Compradores e vendedores utilizam frequentemente métricas generalistas e padronizadas para definir o valor dos automóveis; contudo, estas tabelas estáticas não capturam a realidade dinâmica do mercado, ignorando fatores cruciais de depreciação, como a quilometragem exata, a procura regional e o desgaste específico das diferentes versões e motorizações de um mesmo modelo.

Neste contexto, o Toyota Corolla Sedã foi escolhido para este estudo por ser um dos veículos de maior liquidez e retenção de valor no mercado sul-americano. Criar um modelo de precificação inteligente para este nicho específico permite identificar anomalias de mercado (carros subvalorizados ou supervalorizados) com alta precisão matemática, gerando uma vantagem analítica real para negociações e gestão de frotas.

O objetivo central deste trabalho é desenvolver um modelo preditivo baseado em algoritmos de *Machine Learning* (Regressão) capaz de estimar o preço justo de mercado de veículos do modelo Toyota Corolla Sedã no estado de São Paulo. O modelo utilizará dados reais e atualizados de anúncios para aprender os padrões de depreciação com base no ano de fabricação, versão e quilometragem rodada, superando as limitações das avaliações estáticas atualmente disponíveis ao mercado. Como objetivos específicos, o projeto busca: (i) coletar um dataset representativo e atualizado via web scraping; (ii) realizar a limpeza e análise exploratória dos dados; (iii) treinar e validar modelos de regressão; e (iv) comparar o desempenho do modelo contra a Tabela FIPE como linha de base (baseline).

2. Referencial Teórico

O conceito de assimetria de informação em mercados de bens usados foi amplamente estudado pela teoria econômica. Varian (2019) descreve como mercados com informação imperfeita produzem seleção adversa, onde o preço de equilíbrio tende a refletir a média do mercado em vez do valor real de cada ativo individual. No contexto automobilístico brasileiro, a Tabela FIPE opera precisamente nesta lógica: oferece um valor médio para determinado modelo/ano, ignorando o estado de conservação real do veículo.

O aprendizado de máquina supervisionado, especificamente para tarefas de regressão, permite que um algoritmo aprenda padrões a partir de dados históricos para realizar previsões numéricas contínuas. Segundo James et al. (2021), modelos de regressão estimam a função que relaciona variáveis independentes (*features*) a uma variável dependente (*target*), minimizando o erro de predição sobre o conjunto de treinamento. Para este projeto, as *features* são o Ano do Modelo, a Quilometragem e a Versão do veículo; a variável alvo é o preço de mercado. Géron (2019) detalha que algoritmos como a Regressão Linear Múltipla fornecem uma base interpretável, enquanto métodos de *ensemble* como *Random Forest* e *Gradient Boosting* geralmente

oferecem maior capacidade preditiva ao capturar relações não lineares entre variáveis. Para a fase N2 deste projeto, ambas as abordagens serão avaliadas e comparadas utilizando métricas de erro como o *MAE* (*Mean Absolute Error*) e o *RMSE* (*Root Mean Square Error*).

A extração automatizada de dados de páginas web, conhecida como *web scraping*, consiste em recuperar e estruturar informações publicamente disponíveis em formato HTML. McKinney (2017) ressalta que a qualidade e a representatividade do dataset são determinantes para o desempenho de qualquer modelo analítico, justificando o investimento técnico na coleta de dados originais em detrimento de datasets genéricos. A biblioteca *Beautiful Soup*, documentada por Richardson (2023), é amplamente utilizada para o parsing de estruturas HTML, enquanto frameworks de automação de navegadores como o *Selenium* permitem a interação com páginas de renderização dinâmica.

O *Scikit-Learn* é a biblioteca de *Machine Learning* mais amplamente adotada no ecossistema Python para fins científicos e de produção. Pedregosa et al. (2011) descrevem sua arquitetura baseada em uma API consistente (fit/predict/transform), que permite a implementação, validação cruzada e comparação de diferentes algoritmos com mínima refatoração de código, tornando-o ideal para projetos acadêmicos que demandam experimentação comparativa de modelos.

3. Metodologia

O desafio técnico consiste em prever o valor financeiro de um veículo usado considerando as suas características únicas, mitigando a dependência de avaliações baseadas puramente na intuição humana ou em médias defasadas. Trata-se de um problema de regressão supervisionada, onde o modelo deve aprender, a partir de um conjunto de anúncios reais, a função de depreciação que mapeia as características observáveis de um veículo ao seu preço de mercado.

Para resolver este problema, foi desenvolvido um *script* próprio em Python para realizar a extração automatizada (*web scraping*) de dados originais a partir de plataformas de classificados automóveis. Utilizando as bibliotecas *Selenium* com *undetected_chromedriver* (para contornar sistemas de detecção de *bots*) e *BeautifulSoup* para o parsing do HTML, conforme Richardson (2023), a pesquisa foi parametrizada para isolar estritamente o modelo Toyota Corolla Sedã em um raio de 100 km da capital São Paulo. O pipeline de coleta percorreu 20 páginas de resultados da plataforma, com deduplicação automática baseada no conjunto de atributos {Versão, Ano, Quilometragem, Preço}, resultando em um dataset original de 991 anúncios únicos. As variáveis extraídas foram: Nome do veículo, Versão, Ano de fabricação/modelo, Quilometragem, Cidade de anúncio e Preço.

Na etapa de Análise Exploratória de Dados, realizada com *Pandas* e *Seaborn* conforme as práticas descritas por McKinney (2017), as informações extraídas em formato de texto bruto foram higienizadas e convertidas em matrizes numéricas. O processo envolveu: (i) remoção do prefixo "R\$" e conversão da coluna de preços para inteiros; (ii) remoção do sufixo "Km" e conversão da quilometragem para inteiros; (iii)

extração do Ano do Modelo a partir da string composta (ex.: "2023/2024"); e (iv) remoção de valores nulos e filtragem de outliers severos com o intervalo válido definido entre R\$ 20.000 e R\$ 300.000.

4.Aspectos Éticos e de Responsabilidade

No desenvolvimento desta solução analítica, a equipe observou rigorosamente os seguintes princípios éticos e de responsabilidade tecnológica:

Privacidade e Coleta de Dados: A raspagem de dados incidiu exclusivamente em informações públicas e comerciais, de livre acesso na internet. Nenhum dado pessoal sensível de usuários ou vendedores (como nomes, contatos telefônicos, endereços ou documentos de identificação) foi extraído ou armazenado, garantindo o cumprimento integral da Lei Geral de Proteção de Dados (LGPD) vigente no Brasil.

Transparência e Uso do Modelo: O algoritmo preditivo tem como propósito atuar como uma ferramenta de suporte à decisão matemática, e não como um instrumento absoluto de fixação de preços de mercado. A documentação do projeto garante a transparência de que o modelo opera com uma margem de erro estatística inerente, e os resultados devem ser interpretados como estimativas probabilísticas, não como valores determinísticos.

Prevenção de Vieses Algorítmicos: A equipe restringiu o escopo da coleta a uma região geográfica controlada e isolou o formato de carroceria (Sedã) para evitar que o modelo crie discriminações de preços baseadas na saturação de anúncios de diferentes regiões ou misture veículos de categorias com curvas de depreciação distintas. O modelo final será testado para garantir que avalia os veículos puramente por seus atributos objetivos de conservação.

5. Resultados e discussão

Após o processo de limpeza e filtragem, o dataset final preservou todos os 991 anúncios originais, demonstrando a alta qualidade dos dados extraídos. A Tabela 1 apresenta as estatísticas descritivas das três variáveis numéricas principais do dataset limpo.

Tabela 1 – Estatísticas Descritivas do Dataset Limpo (n = 991)

Variável	Mínimo	Mediana	Média	Máximo
Preço (R\$)	26.900	126.000	123.668	296.990
Quilometragem (km)	0	75.000	82.164	350.000
Ano do Modelo	2001	2022	2020	2026

A amplitude de preços observada (de R\$ 26.900, modelos de 2001 com alta quilometragem, a R\$ 296.990, modelos 2026 híbridos zero km) evidencia a

heterogeneidade do mercado de Corolla em São Paulo e a insuficiência de um único valor médio para representar esse espectro. O desvio padrão de R\$ 40.885 reforça que a variância do preço é matematicamente significativa e dependente de características individuais do veículo.




Figura 1 - Dispersão e Distribuição de Preços do Dataset Limpo

A principal hipótese do projeto de que existe correlação negativa entre quilometragem e preço foi confirmada empiricamente através da análise gráfica. A Figura 1 apresenta os dois gráficos produzidos durante a EDA: um *scatter plot* (dispersão) que evidencia a curva de depreciação em função do desgaste do veículo, e um *boxplot* que demonstra a distribuição de preços segmentada por ano de fabricação. O gráfico de dispersão (esquerda) confirma de forma visual e inequívoca a correlação negativa entre quilometragem rodada e preço de anúncio. Veículos com 0 km apresentam preços concentrados entre R\$ 150.000 e R\$ 300.000, enquanto veículos com 200.000 km ou mais raramente ultrapassam R\$ 80.000. Esta relação é consistente com os fundamentos econômicos de depreciação por uso, e sua evidência estatística válida a viabilidade de um modelo de regressão para a etapa seguinte, conforme argumentado por James et al. (2021). O *boxplot* por ano de modelo (direita) revela uma curva de valorização temporal clara: modelos de 2001 concentram-se na faixa de R\$ 25.000–R\$ 40.000, enquanto modelos de 2025-2026 atingem medianas superiores a R\$ 180.000. A presença de *outliers* em anos recentes como 2024 e 2025 indica anúncios de versões híbridas e de alto desempenho, que se distanciam do padrão de depreciação convencional da linha XEi/GLi. Esta observação sugere que a variável "Versão" deverá exercer peso considerável no modelo preditivo final.

Do total de 991 anúncios, 100 cidades distintas do estado de São Paulo foram representadas, com São Paulo (capital) respondendo por 306 anúncios (aproximadamente 31% do total). Essa concentração é esperada dado o escopo geográfico definido de 100 km em torno da capital, e é estatisticamente favorável ao modelo, pois reduz a variância de precificação introduzida por diferenças de mercado regional entre estados.

6. Conclusão

A primeira fase do projeto demonstrou a viabilidade técnica de extrair e tratar dados reais do mercado automóvel de forma automatizada. A coleta de 991 anúncios únicos de Toyota Corolla Sedã na região de São Paulo constituiu um dataset original, representativo e atualizado (aspecto que diferencia este trabalho de abordagens que utilizam datasets genéricos ou defasados).

A higienização do *dataset* e a análise exploratória evidenciaram padrões matemáticos consistentes com a teoria econômica de depreciação: a correlação negativa entre quilometragem e preço foi confirmada graficamente, e a distribuição de preços por ano de modelo revela uma curva de valorização temporal clara com heterogeneidade entre versões. Esses resultados validam a aplicação de algoritmos de *Machine Learning* de regressão nas etapas subsequentes, garantindo uma base sólida de treinamento para os modelos a serem implementados com o framework Scikit-Learn (PEDREGOSA et al., 2011).

Como trabalhos futuros imediatos, o projeto prevê: o treinamento e validação de modelos de Regressão Linear Múltipla, *Random Forest Regressor* e *XGBoost*; a comparação do desempenho dos modelos usando MAE e RMSE; e a utilização da Tabela FIPE como baseline de comparação para atestar o ganho preditivo da abordagem de aprendizado de máquina sobre as métricas estáticas de mercado.

7. Referências bibliográficas

GÉRON, Aurélien. *Hands-on machine learning with Scikit-Learn, Keras, and TensorFlow: concepts, tools, and techniques to build intelligent systems*. 2. ed. Sebastopol: O'Reilly Media, 2019.

JAMES, G.; WITTEN, D.; HASTIE, T.; TIBSHIRANI, R. *An introduction to statistical learning: with applications in R*. 2. ed. New York: Springer, 2021.

MCKINNEY, Wes. *Python for data analysis: data wrangling with Pandas, NumPy, and IPython*. 2. ed. Sebastopol: O'Reilly Media, 2017.

PEDREGOSA, Fabian et al. Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, v. 12, p. 2825-2830, 2011.

RICHARDSON, Leonard. *Beautiful Soup Documentation*. 2023. Disponível em: <https://www.crummy.com/software/BeautifulSoup/bs4/doc/>. Acesso em: 24 mar. 2026.

VARIAN, Hal R. *Intermediate Microeconomics: A Modern Approach*. 9. ed. New York: W. W. Norton & Company, 2019.